# Template de Planejamento de Documentação e Artigo

**Nome da Documentação/Artigo:** Fundamentos de Engenharia de IA

**Área de Estudo:** Agentes/LLMs

**Integrantes do Grupo:**

- **Gabriel Fernandes Marchesano**
- **Enzo Henrique Dias Ribeiro**
- **Erick Belleza Spina**
- **Juliana Kaori Suzuki**

**Coordenador(es) do Grupo:**

---

## 1. Introdução:

### 1.1. Descrição do Tema

A área de **Engenharia de IA** consiste na aplicação de práticas rigorosas de engenharia de software para projetar, orquestrar e sustentar aplicações baseadas em Grandes Modelos de Linguagem (LLMs). O projeto abordará o ciclo completo de desenvolvimento dessas soluções, cobrindo desde a parametrização de APIs e Engenharia de Prompt até a construção de Agentes de IA autônomos capacitados com ferramentas (*Function Calling*), arquiteturas avançadas de Recuperação Aumentada por Geração (como *Agentic RAG* e *Graph RAG*) e a criação de AI

Harnesses para testes automatizados (*Evals*), observabilidade e segurança de dados.

O mercado vem passando por uma transição de protótipos de chat para sistemas cognitivos integrados em produção. Isso ajuda as empresas que buscam adotar a IA a mitigar o não-determinismo e alucinações dos modelos, conectar LLMs a bases de dados corporativas em tempo real sem re-treinamentos custosos, automatizar fluxos operacionais complexos de ponta a ponta e garantir governança por meio de métricas claras de desempenho, latência e custo.

### 1.2. Objetivos da Documentação

- Apresentar e descrever as principais técnicas que envolvem chamadas de LLM's, e a criação de agentes de IA que usam desses modelos

## 2. Plano de Estudo e Pesquisa:

### 2.1. Estrutura de Conteúdo

#### 1: Fundamentos de LLMs e Chamadas de API

- Parâmetros de Modelos: Entendimento prático de parâmetros como *temperature*, *top_p*, *frequency_penalty*, e limites de *max_tokens*.
- Formatos de Entrada e Saída: Estruturação de papéis (*System*, *User*, *Assistant*) e garantia de respostas estruturadas (Saídas em JSON / Structured Outputs).

#### 2: Engenharia de Prompt e Gerenciamento de Contexto

- Técnicas de Prompting: Zero-shot, Few-shot, Chain-of-Thought (CoT) e ReAct.
- Gerenciamento de Janela de Contexto: Estratégias para lidar com limites de memória do modelo, incluindo sumarização dinâmica, truncation e compressão de histórico.

### 3: RAG (Retrieval-Augmentation Generation)

- Ingestão e Processamento de Dados: *Chunking* (divisão de textos) e geração de *Embeddings*.
- Bancos de Dados Vetoriais (Vector DBs)
- RAG vs Fine-Tuning
- Grafos de conhecimento

### 4: Agentes de IA e Uso de Ferramentas (Tools / Function Calling)

- Conceito de Agente
- Function Calling & Tools
- Agentic RAG
- Orquestração e Arquitetura Multi-Agente

### 5: Tópicos Avançados

- AI Harness e Evaluation Harness
- Segurança
- Observabilidade

## 2.2. Metodologia de Pesquisa

- 

# 3. Divisão de Etapas e Entregas:

**Forma de entrega:** Cada etapa deve ser entregue para o email hype-each@usp.br com o assunto "Nome Do Projeto - Etapa X", anexando-se o documento da sua pesquisa (com exceção da Etapa 0).

## Etapa 0: Definição de grupos e preenchimento deste documento

- **Data:** 27/09
- **Descrição:** Una-se com seu grupo, faça uma cópia deste documento, preencha-o e o envie via email até a data acima.

## Fund. Engenharia de IA - Etapa 1: Tópicos/Capítulos 1 e 2

- **Data:** 17/10
- **Descrição:** Criação de código de documentação estruturada - notebooks que cobrem as técnicas de uso dos LLM's, i.e. boas práticas de prompt e contexto, com aplicações simples de exemplo

## Fund. Engenharia de IA - Etapa 2: RAG(Capítulo 3)

- **Data:** 07/11
- **Descrição:** Criação de código de documentação estruturada - pipeline RAG simples contendo chunking, embeddings, banco de dados vetoriais, recuperação e geração(rag-pipeline-guide), comparação entre RAG e fine-tuning e evolução dessa técnica

## Fund. Engenharia de IA - Etapa 3: Tópicos/Capítulos 4 e 5

- **Data:** 05/12
- **Descrição:** Criação de agente de IA para uma funcionalidade x (simples) para fim de exemplificar e instruir na criação de agentes(cáp 4). Iniciar o estudo e documentação do conteúdo de tópicos avançados seguindo o padrão das etapa 1 e 2

## Fund. Engenharia de IA - Etapa 4: Documentação completa + Artigo

- **Data:** (Fevereiro 27) - a depender do período de férias do hype
- **Descrição:** Finalizar a documentação de Harness e produzir um artigo na Newsletter sobre uma técnica do estado da arte(ou próximo dele) dentre as que estudamos

## 4. Referências Bibliográficas:

Listar os artigos, livros e materiais usados como base para o desenvolvimento do projeto.